



**SISTEMA INTELIGENTE DE EXTRAÇÃO AUTOMÁTICA DE DADOS EM NOTAS FISCAIS
UTILIZANDO OCR E LARGE LANGUAGE MODELS**

Cesar Chiodi Siqueira¹
André Luiz da Silva²
Fabiana Florian³

Resumo: Este trabalho apresenta uma proposta de automação do processamento de notas fiscais utilizando técnicas de Reconhecimento Óptico de Caracteres (OCR) e Modelos de Linguagem de Grande Escala (LLMs). O objetivo é criar um sistema que reconheça, interprete e gerencie informações estruturadas em documentos fiscais, reduzindo o trabalho manual e erros humanos. Faremos uma prova de conceito, onde documentos com formato de imagem ou PDF passarão por um processo de extração de texto, seguido por interpretação e organização dos dados com técnicas de inteligência artificial. O sistema inclui uma dupla validação, sistêmica e humana, para garantir uma maior confiabilidade nos resultados. Esses resultados devem indicar um aumento na precisão da extração de dados, menos inconsistências e mais eficiência no processamento dos documentos. A integração entre reconhecimento de caracteres e modelos de linguagem representa uma solução moderna e eficaz para a automação de processos documentais, contribuindo para a evolução das rotinas administrativas, contábeis e humanas.

Palavras-chave: inteligência artificial, automação, LLM, notas fiscais, OCR, prova de conceito, PDF.

¹ Graduando do Curso de Sistemas de Informação Cesar Chiodi Siqueira da Universidade de Araraquara-UNIARA. Araraquara-SP. E-mail: ccsiqueira@uniara.edu.br

² Orientador. Docente do Curso de Sistemas de Informação André Luiz da Silva da Universidade de Araraquara-UNIARA. Araraquara-SP. E-mail: alsilva@uniara.edu.br

³ Coorientador. Docente do Curso de Sistemas de Informação Fabiana Florian da Universidade de Araraquara-UNIARA. Araraquara-SP. E-mail: fflorian@uniara.edu.br

INTELLIGENT SYSTEM FOR AUTOMATIC DATA EXTRACTION FROM INVOICES USING OCR AND LARGE LANGUAGE MODELS.

Abstract: This work focuses on automating the processing of tax invoices using an OCR tool for optical character recognition and large-scale language models (LLM). The goal is to create a system that recognizes, interprets, and manages structured information in tax documents, reducing manual work and human error. We will conduct a proof of concept where documents in image or PDF format will undergo a text extraction process, followed by data interpretation and organization using artificial intelligence techniques. The system includes dual validation, both systemic and human, to ensure greater reliability in the results. These results should indicate an increase in the accuracy of data extraction, fewer inconsistencies, and greater efficiency in document processing. The integration between character recognition and language models represents a modern and effective solution for automating document processes, contributing to the evolution of administrative, accounting, and human routines.

Key-words: Artificial intelligence, automation, LLM, invoices, OCR, proof of concept, PDF.

1 INTRODUÇÃO

A crescente digitalização dos processos organizacionais tem impulsionado a adoção de tecnologias voltadas à automação de atividades administrativas e documentais. Entre essas atividades, destaca-se o processamento de documentos fiscais, que desempenha papel fundamental nos processos contábeis, financeiros e de auditoria das organizações. Apesar dos avanços tecnológicos observados nas últimas décadas, muitas empresas ainda realizam a extração e o lançamento de informações contidas em notas fiscais de forma manual, tornando o processo suscetível a erros, retrabalho e perda de produtividade.

O Reconhecimento Óptico de Caracteres (Optical Character Recognition – OCR) tem sido amplamente utilizado para converter imagens e documentos digitalizados em texto processável por sistemas computacionais. Segundo Smith (2007), essa tecnologia representa um importante avanço para a digitalização documental, permitindo automatizar tarefas anteriormente executadas manualmente. Entretanto, soluções tradicionais de OCR apresentam limitações relacionadas à interpretação semântica das informações extraídas, especialmente quando aplicadas a documentos com layouts variados, baixa qualidade de imagem ou estruturas complexas.

Nos últimos anos, técnicas baseadas em aprendizado profundo têm contribuído significativamente para a evolução dos sistemas de reconhecimento e da compreensão de documentos. Li et al. (2023) demonstraram que modelos estruturados de inteligência artificial são capazes de melhorar a precisão na identificação de informações presentes em documentos fiscais, reduzindo falhas observadas em abordagens convencionais. Paralelamente, o desenvolvimento dos Modelos de Linguagem de Grande Escala (Large Language Models – LLMs) ampliou a capacidade dos sistemas computacionais de compreender contexto, interpretar informações e estruturar dados extraídos de textos não organizados (JURAFSKY; MARTIN, 2023).

Nesse contexto, torna-se relevante investigar de que forma a integração entre tecnologias de OCR e modelos de linguagem pode contribuir para a automação do processamento de notas fiscais eletrônicas. Pressupõe-se que a utilização conjunta dessas tecnologias seja capaz de aumentar a precisão da extração de informações, reduzir a necessidade de intervenção manual e minimizar inconsistências no tratamento de documentos fiscais.

Dessa forma, o presente trabalho tem como objetivo desenvolver uma prova de conceito de um sistema inteligente para extração automática de dados em notas fiscais eletrônicas, utilizando OCR e modelos de linguagem. A solução proposta busca identificar e estruturar informações relevantes, como empresa emissora, Cadastro Nacional da Pessoa Jurídica, data de emissão, número da nota fiscal e valor total do documento.

Quanto aos procedimentos metodológicos, a pesquisa caracteriza-se como aplicada e de natureza exploratória, com abordagem qualitativa e quantitativa. O estudo será desenvolvido por meio de pesquisa bibliográfica e desenvolvimento experimental de uma

prova de conceito, composta por um módulo de OCR responsável pela extração textual dos documentos e um modelo de linguagem encarregado da interpretação e estruturação das informações obtidas. Os resultados serão avaliados a partir da precisão dos dados extraídos, da ocorrência de inconsistências identificadas durante o processamento e da necessidade de correções realizadas na etapa de validação humana.

O artigo está estruturado em seções que abordam a fundamentação teórica sobre OCR, modelos de linguagem e automação documental, a metodologia empregada, a descrição da solução proposta e a análise dos resultados obtidos.

2 REVISÃO BIBLIOGRÁFICA

2.1 Reconhecimento Óptico de Caracteres (OCR)

O reconhecimento óptico de caracteres (OCR) é uma tecnologia que permite a conversão de imagens contendo texto em dados textuais processáveis por sistemas computacionais. Essa tecnologia tem sido amplamente utilizada na digitalização de documentos, automação de processos administrativos e extração de informações.

Segundo estudos recentes, como o trabalho de Zhijie Li e colaboradores, o uso de técnicas baseadas em aprendizado profundo tem melhorado significativamente a precisão dos sistemas de OCR, especialmente em documentos complexos como faturas e notas fiscais.

Li et al. (2023) demonstraram que abordagens voltadas ao reconhecimento estruturado podem considerar não apenas o texto, mas também características relacionadas à organização do documento, o que é relevante quando diferentes campos aparecem em posições distintas.

Entretanto, apesar dos avanços, o OCR tradicional ainda apresenta limitações quando aplicado a documentos com diferentes layouts, baixa qualidade de imagem ou presença de ruídos. Isso ocorre porque a tecnologia foca na extração de texto, mas não compreende o contexto das informações extraídas.

O funcionamento dos sistemas OCR é normalmente composto por etapas de pré-processamento da imagem, segmentação dos caracteres, reconhecimento textual e pós-processamento dos resultados. O pré-processamento busca melhorar a qualidade visual do documento por meio de técnicas como remoção de ruídos, ajuste de contraste e binarização da imagem. Essas etapas são consideradas fundamentais para aumentar a taxa de reconhecimento dos caracteres e reduzir erros de interpretação, especialmente em documentos digitalizados com baixa qualidade (SMITH, 2007).

A evolução dos sistemas OCR acompanhou o avanço das técnicas de inteligência artificial. Enquanto as primeiras soluções utilizavam regras fixas e reconhecimento por padrões previamente definidos, os modelos modernos empregam redes neurais profundas capazes de identificar caracteres em diferentes fontes, tamanhos e condições de iluminação. Segundo Goodfellow, Bengio e Courville (2016), a aplicação de técnicas de Deep Learning permitiu ganhos significativos de precisão em tarefas de reconhecimento visual, tornando possível o processamento automatizado de documentos cada vez mais complexos.

2.2 Inteligência Artificial e Processamento de Linguagem Natural

A evolução da inteligência artificial, especialmente na área de Processamento de Linguagem Natural (PLN), possibilitou o desenvolvimento de modelos capazes de compreender e interpretar textos de forma contextualizada.

Os modelos de linguagem de grande escala (LLMs) utilizam redes neurais profundas treinadas com grandes volumes de dados, permitindo identificar padrões linguísticos e extrair informações estruturadas a partir de textos não estruturados.

Esses modelos têm sido aplicados em diversas áreas, incluindo chatbots, análise de sentimentos, tradução automática e, mais recentemente, na interpretação de documentos.

O Processamento de Linguagem Natural constitui uma área da inteligência artificial dedicada à interação entre computadores e linguagem humana. Seu objetivo é permitir que sistemas computacionais compreendam, interpretem e gerem informações textuais de maneira semelhante ao raciocínio humano. De acordo com Jurafsky e Martin (2023), essa área engloba atividades como classificação de textos, extração de entidades, tradução automática, sumarização e interpretação semântica.

Nos últimos anos, os Modelos de Linguagem de Grande Escala passaram a representar um marco na evolução do Processamento de Linguagem Natural. Esses modelos são treinados utilizando bilhões de palavras provenientes de diferentes fontes textuais, permitindo identificar relações complexas entre conceitos e contextos. Como resultado, tornaram-se capazes de executar tarefas que anteriormente exigiam regras específicas ou intervenção humana, incluindo a extração estruturada de informações presentes em documentos corporativos.

Brown et al. (2020) demonstraram a capacidade de modelos de grande escala realizarem diferentes tarefas a partir de instruções e poucos exemplos. Chowdhery et al. (2023) também apresentaram resultados relacionados à ampliação da escala desses modelos, evidenciando o avanço da área.

2.3 Integração entre OCR e Modelos de Linguagem

A combinação entre OCR e modelos de linguagem representa uma abordagem promissora para o processamento inteligente de documentos. Enquanto o OCR é responsável pela extração do texto bruto, os LLMs atuam na interpretação e organização das informações.

De acordo com Li et al. (2023), modelos estruturais como o StrucTexT conseguem identificar não apenas o conteúdo textual, mas também a estrutura dos documentos, melhorando a precisão na extração de campos relevantes, como valores e identificadores.

Essa integração permite superar limitações do OCR tradicional, possibilitando a construção de sistemas mais robustos e adaptáveis a diferentes tipos de documentos.

A integração entre OCR e modelos de linguagem tem sido apontada como uma das abordagens mais promissoras para o processamento inteligente de documentos. Nessa arquitetura, o OCR atua como mecanismo de conversão da imagem em texto, enquanto o modelo de linguagem é responsável por interpretar o conteúdo extraído, identificar entidades relevantes e organizar as informações em estruturas adequadas para utilização por sistemas computacionais.

Essa abordagem apresenta vantagens significativas em comparação aos métodos tradicionais baseados exclusivamente em OCR. Em muitos cenários, o texto extraído pode apresentar erros de reconhecimento, caracteres incorretos ou informações posicionadas em diferentes regiões do documento. A utilização de modelos de linguagem permite analisar o contexto das informações e inferir correções quando necessário, aumentando a robustez e confiabilidade do processo de extração. Conforme demonstrado por Li et al. (2023), modelos estruturados capazes de compreender simultaneamente conteúdo textual e layout documental apresentam desempenho superior na identificação de campos relevantes em documentos fiscais e faturas.

2.4 Automação de Processos Documentais

A automação de processos documentais tem sido utilizada para reduzir atividades repetitivas e apoiar o tratamento de grandes volumes de informações. A transformação digital também tem incentivado organizações a substituir tarefas manuais por processos apoiados por tecnologias digitais, mantendo mecanismos de controle para situações que exigem conferência humana (VERHOEF et al., 2021).

No contexto brasileiro, onde há grande volume de emissão de notas fiscais eletrônicas e diversidade de formatos, soluções automatizadas podem trazer ganhos significativos para empresas de diferentes portes.

2.5 Validação Humana em Sistemas Automatizados

Apesar dos avanços tecnológicos, a validação humana ainda desempenha um papel importante em sistemas automatizados, especialmente em cenários que exigem alta confiabilidade.

A abordagem conhecida como human-in-the-loop combina automação com intervenção humana, permitindo corrigir possíveis erros do sistema e melhorar continuamente sua precisão.

No contexto deste trabalho, a validação humana é utilizada como etapa final do processamento, garantindo que os dados extraídos estejam corretos antes de serem armazenados e utilizados.

Segundo Amershi et al. (2019), abordagens Human-in-the-Loop permitem combinar a eficiência da automação com a capacidade humana de identificar e corrigir inconsistências.

2.6 Trabalhos Relacionados

Diversos estudos têm investigado a aplicação de técnicas de reconhecimento óptico de caracteres e inteligência artificial para automatizar a extração de informações em documentos empresariais. O crescente volume de documentos digitais e a necessidade de reduzir atividades manuais impulsionaram pesquisas voltadas à melhoria da precisão, velocidade e confiabilidade desses sistemas.

Smith (2007) apresentou uma das principais referências na área ao descrever o funcionamento do mecanismo Tesseract OCR, amplamente utilizado em aplicações de reconhecimento textual. O estudo demonstrou a viabilidade da conversão automatizada de documentos digitalizados em texto processável por sistemas computacionais, tornando-se uma das bases para pesquisas posteriores em automação documental.

Com a evolução das técnicas de aprendizado profundo, novas abordagens passaram a explorar não apenas o reconhecimento de caracteres, mas também a compreensão estrutural dos documentos. Nesse contexto, Li et al. (2023) propuseram o modelo StrucTexT, desenvolvido para reconhecimento estruturado de informações em faturas e documentos fiscais. Os resultados apresentados pelos autores indicaram taxas de acerto superiores às obtidas por soluções tradicionais de OCR, além de redução do tempo de processamento e menor consumo de recursos computacionais.

Além do reconhecimento textual, pesquisas recentes têm investigado o uso de modelos de linguagem para interpretação semântica das informações extraídas. Segundo Jurafsky e Martin (2023), os avanços em Processamento de Linguagem Natural permitiram que modelos modernos identificassem entidades, relações e padrões contextuais em textos não estruturados, ampliando significativamente as possibilidades de automação documental.

Embora os trabalhos existentes apresentem resultados promissores, observa-se que grande parte das soluções concentra-se exclusivamente na etapa de reconhecimento textual ou na interpretação semântica dos dados. Dessa forma, ainda existe a necessidade de abordagens

que integrem OCR, modelos de linguagem e mecanismos de validação para aumentar a confiabilidade das informações extraídas, especialmente em documentos fiscais que apresentam diferentes layouts e níveis de qualidade.

Nesse cenário, o presente trabalho diferencia-se por propor uma solução integrada composta por reconhecimento óptico de caracteres, interpretação contextual por meio de modelos de linguagem e validação humana assistida. Essa combinação busca reduzir limitações observadas em abordagens isoladas, aumentando a precisão da extração de dados e fornecendo maior confiabilidade para utilização das informações em ambientes corporativos.

3 DESENVOLVIMENTO

Este trabalho propõe o desenvolvimento de uma prova de conceito de um sistema inteligente para extração automática de informações presentes em notas fiscais eletrônicas, utilizando a integração entre técnicas de Reconhecimento Óptico de Caracteres (Optical Character Recognition – OCR) e Modelos de Linguagem de Grande Escala (Large Language Models – LLMs). A solução foi concebida para automatizar parte do processo de leitura e organização de informações fiscais que, quando realizado manualmente, pode exigir tempo e apresentar maior possibilidade de erros operacionais.

A implementação será baseada em uma única aplicação, organizada em módulos com responsabilidades específicas e integradas. Essa abordagem mantém o projeto compatível com o escopo de uma prova de conceito, facilita o desenvolvimento, os testes e a manutenção, além de permitir futuras evoluções. A aplicação será responsável pelo recebimento dos documentos, processamento do reconhecimento óptico de caracteres, comunicação com o modelo de linguagem, validação dos dados e persistência das informações.

3.1 Arquitetura da Solução

A arquitetura proposta é composta por cinco componentes principais: módulo de recebimento de documentos, mecanismo de Reconhecimento Óptico de Caracteres, módulo de interpretação baseado em Modelo de Linguagem de Grande Escala, camada de validação e repositório responsável pela persistência das informações processadas.

O processo é iniciado quando o usuário envia uma nota fiscal em formato de imagem ou PDF. A aplicação recebe o arquivo, atribui um identificador único ao documento e encaminha seu conteúdo para a etapa de processamento. Quando necessário, técnicas simples de pré-processamento poderão ser utilizadas para melhorar a qualidade da imagem antes da execução do reconhecimento óptico de caracteres.

Após a extração do texto, o conteúdo é enviado ao modelo de linguagem, que recebe instruções para identificar somente as informações relevantes para o trabalho e retorná-las em uma estrutura previamente definida. A resposta gerada é posteriormente submetida à validação sistêmica e à conferência humana. Quando os dados são considerados corretos, o documento e as informações estruturadas podem ser persistidos no banco de dados e disponibilizados para consultas futuras.

Embora a solução seja organizada em módulos, não será necessário que cada etapa seja executada em componentes distribuídos. O fluxo poderá ser coordenado por um serviço de processamento dentro da própria aplicação, reduzindo a quantidade de código e mantendo a arquitetura compatível com o escopo da pesquisa.

A Figura 1 apresenta a arquitetura geral da solução proposta.




Figura 1 – Arquitetura geral da solução proposta.

Fonte: O autor (2026).

3.2 Fluxo de Processamento dos Documentos

O processamento dos documentos será realizado por meio de um fluxo sequencial composto por múltiplas etapas. Inicialmente, o documento será recebido pela aplicação, identificado por um identificador único e armazenado temporariamente para processamento.

Na sequência, será realizada a extração textual utilizando o mecanismo de Reconhecimento Óptico de Caracteres. O texto produzido poderá apresentar informações desorganizadas, erros de reconhecimento ou elementos desnecessários. Por esse motivo, o conteúdo será encaminhado ao módulo de interpretação, que utilizará um modelo de linguagem para identificar entidades relevantes, interpretar o contexto das informações e organizar os dados em uma estrutura padronizada.

Após a interpretação, os dados serão submetidos à validação sistêmica, responsável por identificar inconsistências, informações ausentes ou respostas incompatíveis com a estrutura esperada. Caso ocorram falhas, o processamento poderá ser repetido ou encaminhado para validação humana. Quando os dados forem considerados válidos, serão apresentados ao usuário para conferência e correção, quando necessário, antes da gravação definitiva.

Finalmente, os dados validados serão persistidos no banco de dados, juntamente com os metadados do processamento, e disponibilizados para consultas futuras. O texto original obtido pelo OCR poderá ser preservado para permitir rastreabilidade e comparação durante a validação.

3.3 Extração de Texto por OCR

A etapa de extração textual será responsável por converter o conteúdo visual dos documentos fiscais em um formato processável computacionalmente. Para a implementação da prova de conceito, propõe-se a utilização do Tesseract OCR, solução consolidada, de natureza *open source* e adequada ao escopo do trabalho.

Antes da execução do OCR, poderão ser aplicadas técnicas simples de pré-processamento de imagem com o objetivo de melhorar a qualidade dos documentos recebidos. Entre essas técnicas destacam-se o redimensionamento, o ajuste de contraste, a remoção de ruídos e a binarização da imagem. Essas operações serão utilizadas somente quando contribuírem para melhorar a leitura do documento e reduzir problemas no reconhecimento (ROSEBROCK, 2016).

O resultado dessa etapa consistirá em um texto bruto contendo as informações identificadas no documento. Entretanto, como o OCR não possui capacidade de interpretação semântica, os dados extraídos necessitarão de processamento adicional para que possam ser convertidos em informações estruturadas. Eventuais erros de reconhecimento serão considerados durante as etapas seguintes, e o texto original poderá ser preservado no registro do documento para permitir rastreabilidade e comparação durante a validação.

3.4 Interpretação das Informações por Modelos de Linguagem

Após a extração textual, o conteúdo será encaminhado a um Modelo de Linguagem de Grande Escala por meio da API do provedor escolhido para a implementação. Essa etapa será

responsável por analisar o texto gerado pelo OCR, identificar automaticamente os campos relevantes presentes na nota fiscal e organizar as informações em uma estrutura padronizada.

O modelo receberá instruções específicas sobre os campos que devem ser identificados, como razão social da empresa emissora, Cadastro Nacional da Pessoa Jurídica (CNPJ), data de emissão, número da nota fiscal e valor total do documento. A utilização de modelos de linguagem permite compreender o contexto das informações, mesmo quando existem diferenças de layout entre documentos distintos, reduzindo a necessidade de regras específicas para cada modelo de documento fiscal processado.

O prompt deverá informar que somente dados presentes no texto fornecido poderão ser utilizados. Quando um campo não estiver disponível ou não puder ser identificado com segurança, a resposta deverá indicar sua ausência. Dessa forma, o modelo não deverá preencher campos com informações presumidas ou não identificadas no texto fornecido pelo OCR, devendo indicar a ausência do dado quando não houver evidência suficiente para sua identificação. Essa orientação tem como objetivo reduzir o risco de inclusão de informações que não foram encontradas no documento. A definição das instruções seguirá princípios de elaboração de prompts discutidos na literatura de Processamento de Linguagem Natural (LIU et al., 2023).

Como saída dessa etapa, o sistema deverá gerar uma estrutura previamente definida, preferencialmente em formato JSON, contendo os dados identificados pelo modelo. Antes de utilizar o resultado, a aplicação verificará se a estrutura está correta e se os campos esperados estão presentes. Respostas incompatíveis com o formato definido serão rejeitadas para impedir que dados inválidos avancem para as próximas etapas.

3.5 Validação dos Dados Extraídos

A confiabilidade das informações representa um fator crítico para sistemas de automação documental. Por esse motivo, a solução proposta incorporará dois mecanismos complementares de validação: a validação sistêmica e a validação humana.

A primeira etapa será realizada automaticamente pela aplicação e verificará a integridade e a consistência dos dados extraídos. Nessa etapa, serão realizadas verificações como o preenchimento de campos obrigatórios, a validação de formatos, a representação das datas, a consistência dos valores monetários e regras simples relacionadas ao Cadastro Nacional da Pessoa Jurídica. Também será verificado se a resposta do modelo de linguagem é compatível com a estrutura esperada pelo sistema.

A segunda etapa será realizada pelo usuário, que poderá revisar e corrigir as informações antes de sua persistência definitiva. Essa abordagem utiliza o conceito Human-in-the-Loop e funciona como uma camada de controle para situações em que o reconhecimento óptico de caracteres ou o modelo de linguagem apresentem resultados incorretos (AMERSHI et al., 2019). Durante essa etapa, o usuário poderá confirmar os dados apresentados pelo sistema ou realizar correções diretamente nos campos identificados, sendo as alterações registradas para fins de rastreabilidade e posterior análise do desempenho da solução.

Quando a resposta estiver em formato inválido ou apresentar inconsistências, o sistema poderá realizar uma nova tentativa de processamento. Para falhas que persistirem, o documento será encaminhado para revisão humana, evitando que informações não validadas sejam armazenadas como definitivas.

3.6 Persistência e Gerenciamento das Informações

Após a validação, os dados serão armazenados em uma base de dados orientada a documentos. O MongoDB será utilizado para armazenar as informações processadas, mantendo em um mesmo registro o identificador do documento, o nome do arquivo, o status do processamento, o texto obtido pelo reconhecimento óptico de caracteres, os dados estruturados e as informações relacionadas à validação.

Uma estrutura simplificada poderá conter os campos `_id`, `file_name`, `status`, `ocr_text`, `extracted_data`, `validated` e `created_at`. O campo `extracted_data` poderá armazenar os dados identificados pelo modelo de linguagem, enquanto as informações de validação poderão registrar a confirmação e eventuais correções realizadas pelo usuário.

Além das informações extraídas, o sistema poderá armazenar metadados relacionados ao processamento, como data de envio, histórico de validações e possíveis correções realizadas pelos usuários. Esse conjunto de informações permitirá a rastreabilidade do processamento documental e facilitará futuras auditorias ou análises de desempenho do sistema.

A utilização de uma base orientada a documentos é adequada ao escopo da prova de conceito porque oferece flexibilidade para lidar com diferentes formatos de documentos fiscais e estruturas de dados variáveis, sem exigir um modelo relacional complexo.

3.7 Interface de Integração e Serviços REST

A interface da solução será disponibilizada por meio de uma API REST (*Application Programming Interface – Representational State Transfer*) desenvolvida em Python, responsável por intermediar a comunicação entre o usuário ou aplicações externas e os módulos internos de processamento do sistema. A API será responsável por receber os documentos e disponibilizar as operações necessárias para acompanhamento, consulta e validação do processamento, mantendo as demais etapas organizadas em serviços internos da própria aplicação.

A API atuará como ponto de entrada e comunicação da aplicação, recebendo os documentos, iniciando o processamento, disponibilizando o resultado da extração e permitindo a atualização ou o reprocessamento das informações.

A utilização de serviços REST favorece a integração com aplicações externas e simplifica o consumo das funcionalidades do sistema. Além disso, possibilita futuras integrações com sistemas corporativos, plataformas de gestão documental e aplicações financeiras.

Entre os principais serviços previstos destacam-se o envio de documentos para processamento, consulta de resultados extraídos, atualização de informações validadas e reprocessamento de documentos quando necessário.

3.8 Implementação da API

Como referência para a implementação da prova de conceito, serão consideradas operações para envio do arquivo, consulta do documento, atualização das informações validadas e solicitação de reprocessamento. Assim, podem ser utilizados os endpoints POST `/api/v1/documents` para envio; GET `/api/v1/documents/{id}` para consulta; PUT `/api/v1/documents/{id}` para atualização; e POST `/api/v1/documents/{id}/reprocess` para um novo processamento.

3.9 Containerização do Ambiente

Para facilitar a execução e a reprodução da prova de conceito, o Docker poderá ser utilizado para empacotar a aplicação e o banco de dados. Uma configuração simples poderá utilizar dois containers principais: um para a aplicação Python, contendo as dependências necessárias, e outro para o MongoDB.

O Docker Compose poderá ser utilizado para iniciar os containers em conjunto, configurar a comunicação entre eles e manter o armazenamento do MongoDB por meio de

volume. Informações sensíveis, como credenciais e chaves de acesso ao serviço de modelo de linguagem, deverão ser fornecidas por variáveis de ambiente, evitando sua inclusão direta no código-fonte.

Os documentos processados e as informações extraídas deverão ser tratados de forma controlada durante a execução da prova de conceito, evitando a exposição desnecessária de dados presentes nas notas fiscais e restringindo o armazenamento às informações necessárias para o processamento e a avaliação da solução.

Essa abordagem contribuirá para a padronização do ambiente de execução e facilitará a reprodução dos testes realizados durante o desenvolvimento da prova de conceito.

3.10 Tratamento de Falhas

A solução deverá tratar falhas de maneira simples e previsível, evitando que operações incompletas sejam consideradas concluídas. Arquivos corrompidos ou em formato não suportado deverão ser rejeitados antes do processamento.

Documentos sem texto reconhecido ou com qualidade insuficiente poderão ser marcados como falha de reconhecimento e encaminhados para novo processamento ou revisão. Falhas de comunicação com o serviço de modelo de linguagem deverão ser tratadas com timeout e uma nova tentativa limitada. Respostas em formato inválido ou com campos incompatíveis deverão ser rejeitadas antes da persistência.

Falhas de acesso ao MongoDB também deverão ser registradas em log, sem considerar a operação como concluída. Dessa forma, o sistema evita apresentar ao usuário um resultado como persistido quando a gravação efetivamente não ocorreu.

Em caso de falha persistente, o documento deverá permanecer em estado de falha para posterior revisão ou reprocessamento. Esse comportamento permitirá identificar problemas durante a execução e manter maior controle sobre a integridade das informações armazenadas.

3.11 Critérios de Avaliação da Solução

A avaliação da prova de conceito será realizada utilizando um conjunto de notas fiscais selecionadas para o experimento, contemplando documentos com diferentes layouts e condições de qualidade de imagem, de modo a verificar o comportamento da solução diante de diferentes características documentais.

Para cada documento, serão definidos previamente os valores esperados dos campos de interesse, permitindo comparar os dados de referência com aqueles extraídos pelo sistema.

Serão considerados, inicialmente, os campos de razão social da empresa emissora, Cadastro Nacional da Pessoa Jurídica (CNPJ), data de emissão, número da nota fiscal e valor total do documento, definidos como campos essenciais para a avaliação da prova de conceito.

Os principais critérios de avaliação serão a quantidade de campos identificados corretamente, a quantidade de correções realizadas durante a validação humana, a taxa de documentos processados com sucesso e o tempo necessário para conclusão do processamento. Também poderá ser comparado o resultado obtido somente com o reconhecimento óptico de caracteres com o resultado do fluxo completo que inclui o modelo de linguagem.

A precisão da extração será determinada pela relação entre a quantidade de campos identificados corretamente e a quantidade total de campos avaliados, permitindo quantificar objetivamente o desempenho do sistema.

Também será realizada uma comparação entre os resultados obtidos pelo OCR isoladamente e aqueles obtidos pelo fluxo completo composto por OCR e modelo de linguagem. Para essa comparação, serão observados o número de campos corretamente identificados, os campos ausentes ou incorretos e a quantidade de correções realizadas durante a validação humana.

Espera-se que a integração entre OCR e modelos de linguagem apresente resultados superiores aos obtidos por abordagens baseadas exclusivamente em reconhecimento óptico de caracteres, especialmente em documentos com estruturas variadas e informações distribuídas em diferentes regiões do layout. A verificação dessa hipótese será realizada por meio do procedimento experimental descrito na seção 3.12.

3.12 Metodologia Experimental

A metodologia experimental será utilizada para avaliar o funcionamento da prova de conceito e verificar a capacidade do sistema de extrair e estruturar informações presentes em notas fiscais eletrônicas. O experimento será realizado a partir de um conjunto de documentos fiscais selecionados de forma a contemplar diferentes layouts, condições de qualidade de imagem e formas de organização das informações, permitindo observar o comportamento da solução diante de diferentes características documentais.

Para cada documento utilizado no experimento, serão definidos previamente os valores de referência dos campos considerados essenciais para a pesquisa: razão social da empresa emissora, Cadastro Nacional da Pessoa Jurídica (CNPJ), data de emissão, número da nota

fiscal e valor total do documento. Esses valores serão utilizados como referência para a comparação com as informações produzidas pelo sistema.

O procedimento experimental será composto por etapas sequenciais. Inicialmente, cada nota fiscal será submetida ao fluxo de processamento da aplicação, passando pelo recebimento do documento, pré-processamento quando necessário, extração textual por OCR e interpretação do conteúdo por meio do modelo de linguagem. Na sequência, os dados estruturados serão submetidos à validação sistêmica e, posteriormente, à conferência humana. As correções realizadas pelo usuário serão registradas para possibilitar a análise da ocorrência e da natureza dos erros identificados durante o processamento.

Também será realizada uma comparação entre duas abordagens: a utilização do OCR isoladamente e a utilização do fluxo integrado de OCR com modelo de linguagem. Para ambas as abordagens, serão considerados os mesmos documentos e os mesmos campos de interesse, permitindo verificar se a utilização do modelo de linguagem contribui para melhorar a organização e a identificação das informações extraídas.

A avaliação dos resultados considerará como principais métricas a quantidade e a proporção de campos identificados corretamente, a quantidade de campos ausentes ou incorretos, a quantidade de correções realizadas durante a validação humana, a taxa de documentos processados com sucesso e o tempo necessário para conclusão do processamento. A taxa de acerto dos campos será calculada pela relação entre a quantidade de campos identificados corretamente e a quantidade total de campos avaliados, multiplicada por cem.

Os resultados obtidos serão organizados em tabelas para facilitar a comparação entre as abordagens avaliadas. A análise também considerará as principais causas de erro observadas durante os testes, como falhas de reconhecimento óptico, informações ausentes ou dificuldades de interpretação do conteúdo extraído. Dessa forma, será possível identificar não apenas o desempenho geral da solução, mas também suas limitações e os pontos que poderão ser aprimorados em trabalhos futuros.

3.13 Limitações da Proposta

A proposta apresenta limitações relacionadas à qualidade e à variedade dos documentos utilizados. Imagens com baixa resolução, documentos parcialmente ilegíveis, arquivos incompletos, distorções e informações ausentes podem reduzir a qualidade do reconhecimento. Da mesma forma, diferentes modelos de nota fiscal podem exigir ajustes no pré-processamento ou nas instruções utilizadas pelo modelo de linguagem.

Outra limitação está relacionada à capacidade do modelo de linguagem de interpretar corretamente todas as informações. O modelo pode produzir respostas incompletas ou incorretas em situações específicas, tornando necessária a manutenção das etapas de validação sistêmica e conferência humana para garantir maior confiabilidade dos resultados.

O escopo inicial será limitado aos campos essenciais definidos no objetivo da pesquisa, como empresa emissora, CNPJ, data de emissão, número da nota fiscal e valor total. Informações mais detalhadas, como itens de produtos e impostos, poderão ser consideradas em possíveis evoluções futuras.

CRONOGRAMA DA PESQUISA

Quadro 1 – Cronograma Trabalho de Conclusão de Curso / 2026

Meses	fev.	mar.	4	5	6	7	8	9	10	11	12
Atividades											
Definição do orientador e Entrega do termo de compromisso		x	x								
Revisão de literatura			x	X							
Coleta dos dados					x	x					
Tabulação dos dados						x	x				
Análise dos resultados							x	x			
Redação final								x	x		
Entrega do termo de autorização da defesa pública										x	
Entrega do arquivo com o resultado do detector de plágio e do artigo para a defesa - banca										x	
Defesa do tcc e revisão para a entrega final										x	x
Entrega do tcc /artigo final e documentos /termos para conclusão da disciplina											x

Fonte: o autor, 2026.

REFERÊNCIAS BIBLIOGRÁFICAS

AMERSHI, Saleema et al. Guidelines for human-AI interaction. In: CHI CONFERENCE ON HUMAN FACTORS IN COMPUTING SYSTEMS, 2019, Glasgow. Proceedings [...]. New York: ACM, 2019.

BROWN, Tom B. et al. Language models are few-shot learners. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 33., 2020. Proceedings [...]. [S. l.]: NeurIPS, 2020. p. 1877-1901.

CHOWDHURY, Aakanksha et al. PaLM: scaling language modeling with pathways. Journal of Machine Learning Research, Cambridge, v. 24, n. 240, p. 1-113, 2023.

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. Deep learning. Cambridge: MIT Press, 2016.

JURAFSKY, Daniel; MARTIN, James H. Speech and language processing. 3. ed. [S. l.]: Pearson, 2023.

LI, Zhijie; TIAN, Wencan; LI, Changhua; LI, Yunpeng; SHI, Haoqi. A structured recognition method for invoices based on StrucText model. Applied Sciences, Basel, v. 13, n. 12, p. 6946-6959, 2023. Disponível em: <https://www.mdpi.com/2076-3417/13/12/6946>. Acesso em: 9 nov. 2025.

LIU, Pengfei et al. Pre-train, prompt, and predict: a systematic survey of prompting methods in natural language processing. ACM Computing Surveys, New York, v. 55, n. 9, 2023.

ROSEBROCK, Adrian. Practical Python and OpenCV: an introductory, example-driven guide to image processing and computer vision. [S. l.]: PyImageSearch, 2016.

RUSSELL, Stuart; NORVIG, Peter. Artificial intelligence: a modern approach. 4. ed. Hoboken: Pearson, 2021.

SMITH, Ray. An overview of the Tesseract OCR engine. In: INTERNATIONAL CONFERENCE ON DOCUMENT ANALYSIS AND RECOGNITION, 9., 2007, Curitiba. Proceedings [...]. Washington, DC: IEEE Computer Society, 2007. p. 629-633.

VERHOEF, Peter C. et al. Digital transformation: a multidisciplinary reflection and research agenda. Journal of Business Research, Amsterdam, v. 122, p. 889-901, 2021.